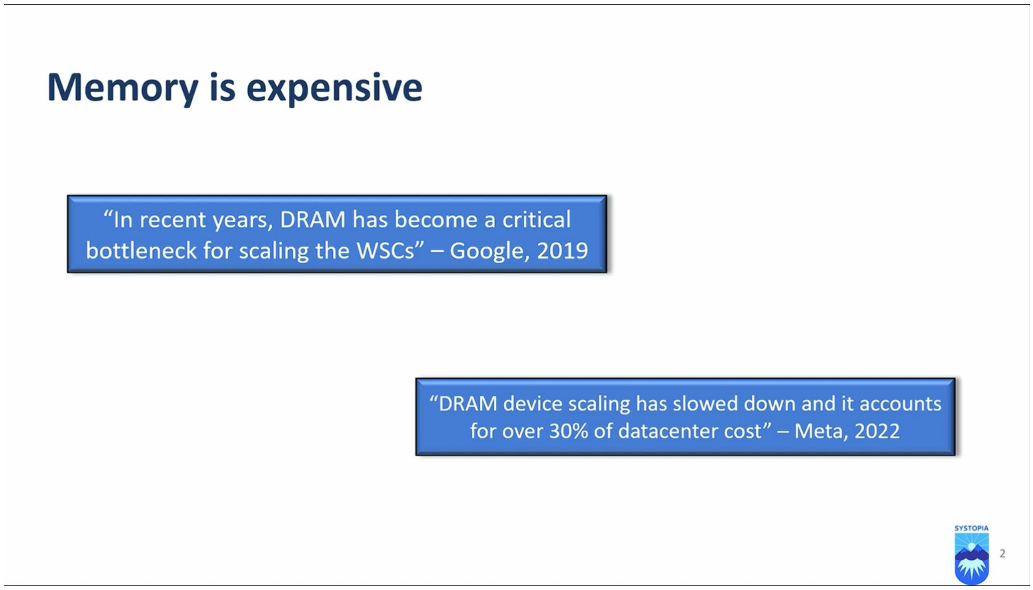

首先，在google和Meta的报告中都指出内存很昂贵

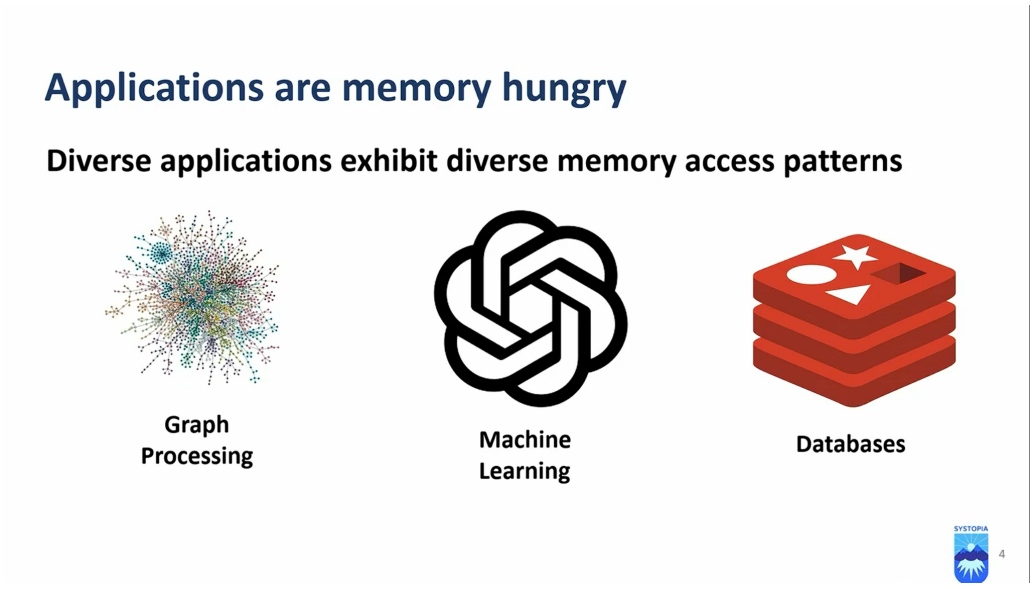

并且，各种类型的应用程序需要大量的内存

不同程序有不同的内存使用方式（图处理：稀疏且高度随机的指针追逐；ML模型：密集的、流式顺序访问；Database：混合模式）

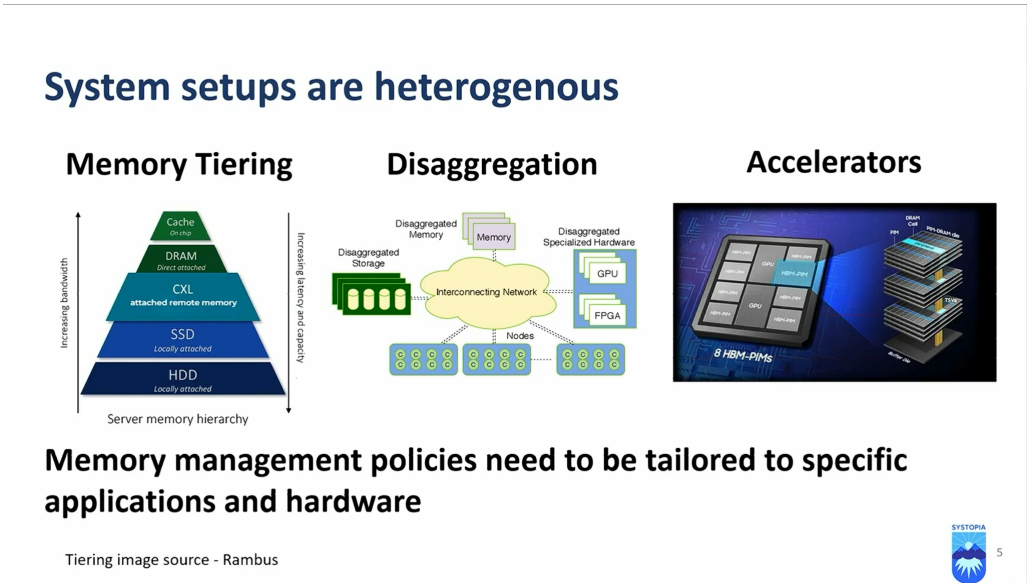

为了减少内存消耗，数据中心的运营商使用了许多技术

内存分层在DRAM内存下加了一层CXL连接的速度较慢但容量更大的拓展内存，通过将频繁访问的热数据迁移到DRAM，将不频繁访问的数据迁移到远程内存，扩大内存容量并降低硬件成本

内存分解将内存资源从计算服务器中物理分离，并通过高速网络将其汇集成一个共享资源池；服务器可以按需从远端的资源池中获取内存（解决单台服务器内存浪费或不足）

另一种方法是使用加速器，用专门的硬件分担CPU在网络和存储I/O等任务上的负载（**Intel VT-d (Virtualization Technology for Directed I/O)** 等技术允许虚拟机直接访问硬件设备（如网卡），绕过hypervisor的软件模拟层，显著降低了I/O延迟）

而内存管理策略需要针对特定的硬件，和在硬件上运行的应用程序进行定制

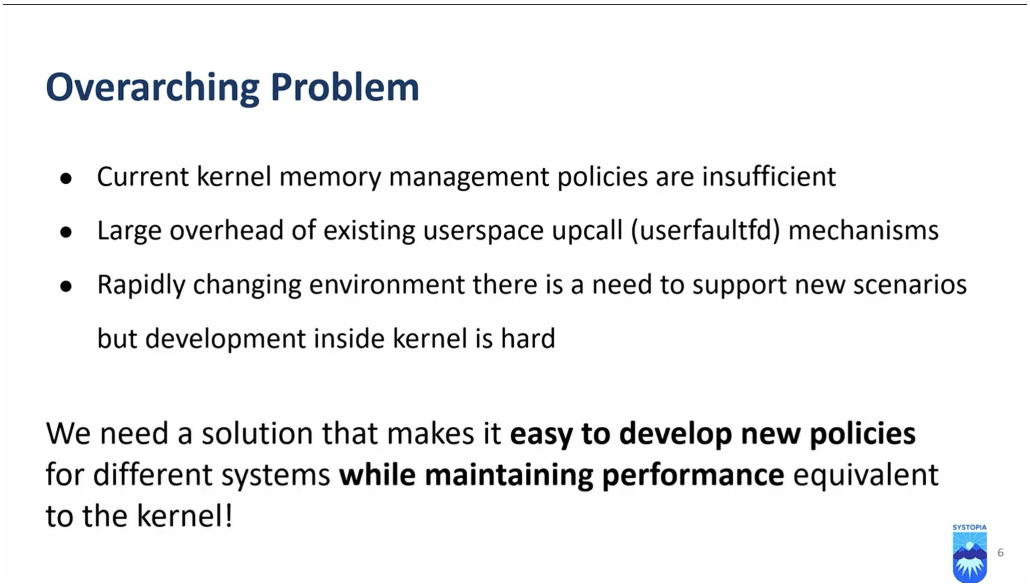

所以，总体的问题是，当前的内存管理策略不足以应对以上说的多种硬件结构、多种应用程序的复杂情况

新的内存管理策略的开发需要涉及到大量的内核代码修改，赶不上环境的快速变化（难以跟上云计算、边缘计算、AI加速器等新兴计算环境的快速演进需求）

有一种叫做userfaultfd的机制，允许将page pault转发给用户态程序处理，以实现**自定义的内存管理策略**，但这样做的开销很大，每次page fault都要面临故障线程与处理线程间的IPC通信成本，在高并发场景下还面临串行化瓶颈问题

所以，这篇论文提出一个解决方案：它能够让定制不同的内存管理策略变得容易，同时，将它的开销维持在和在linux内核中的策略同一水平

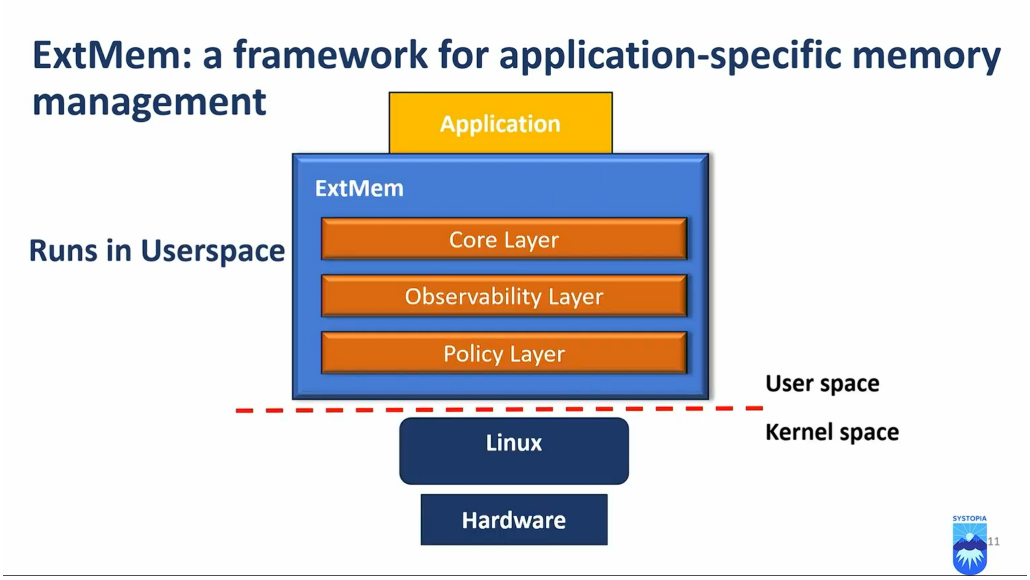

这篇论文实现了ExtMem框架，它运行在用户态，允许用户在用户态实现自定义的内存管理策略

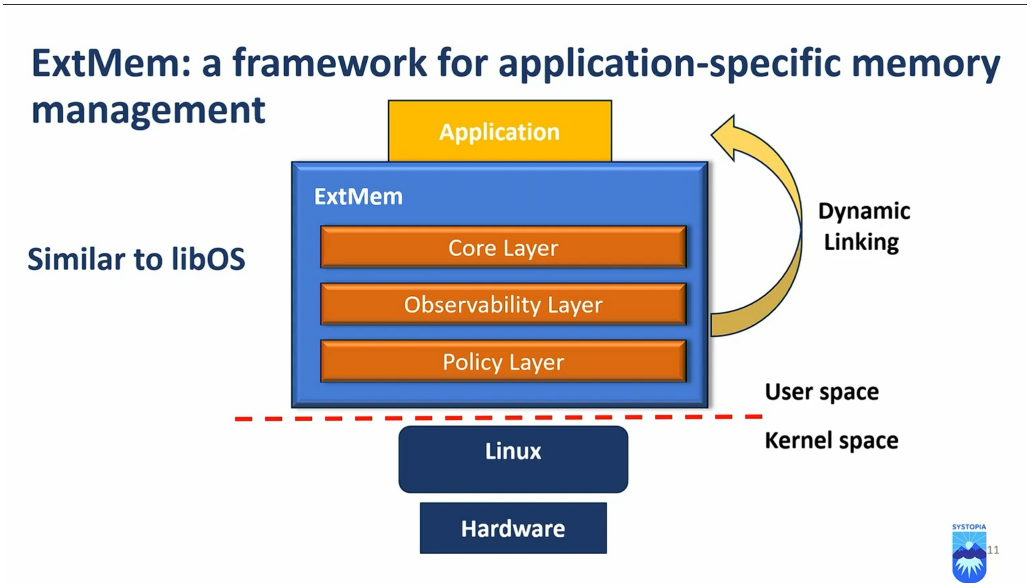

EXTMEM被设计为一个动态链接库，可以被动态地加载到应用程序地址空间中

ExtMem有三个组件

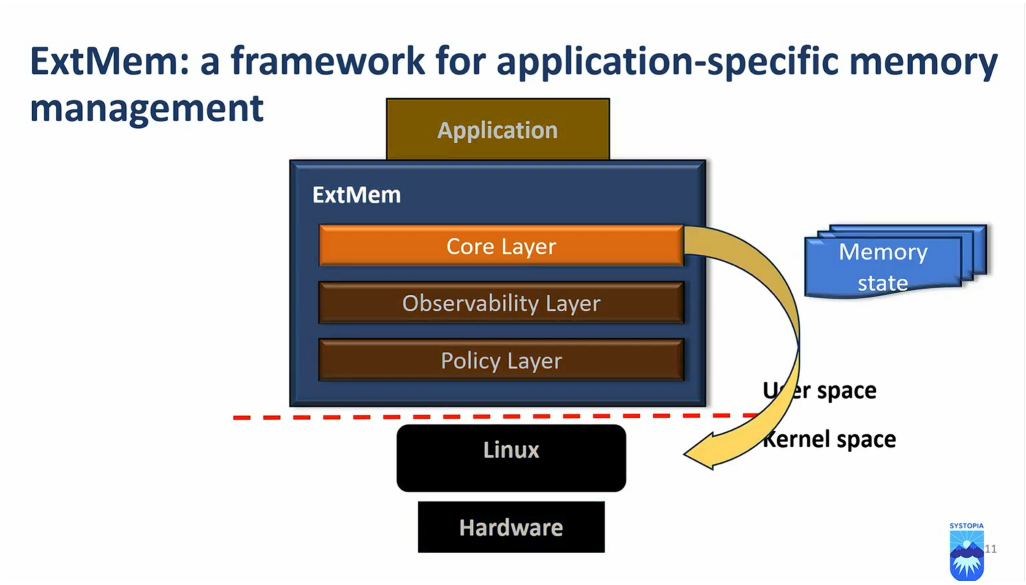

Core Layer：负责管理内存状态，并与内核交互

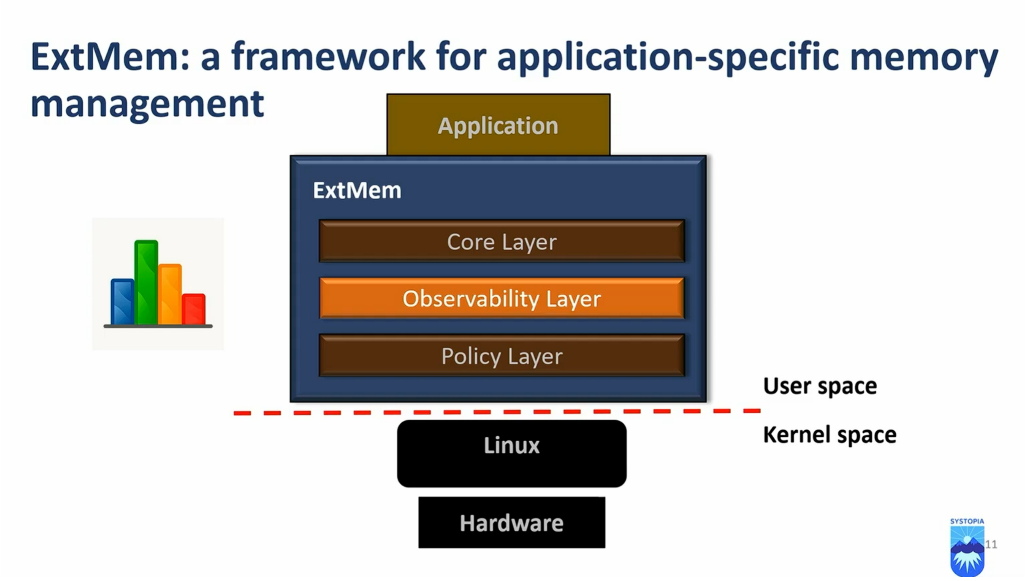

Observability Layer：负责收集用户自定义策略所需的数据

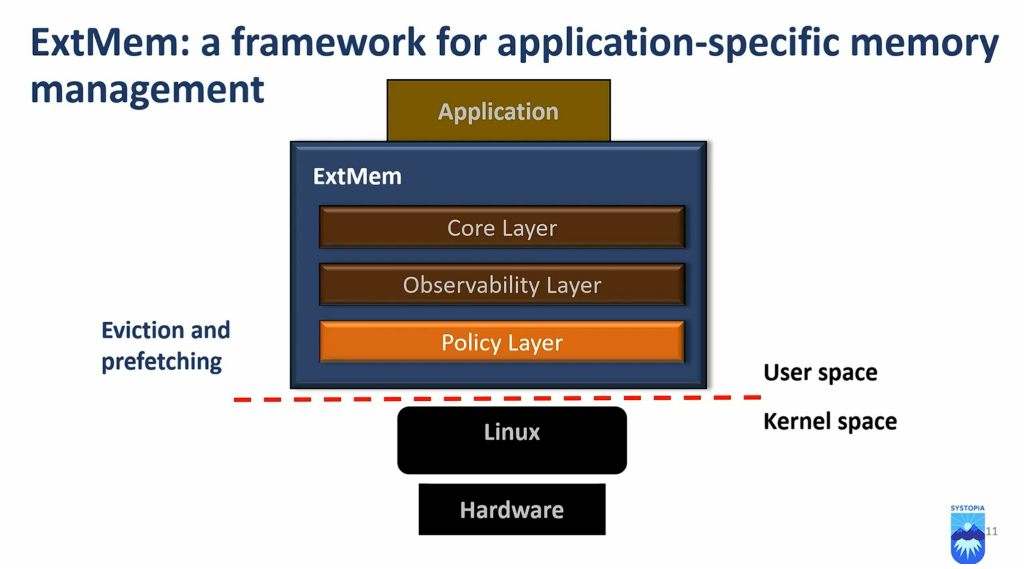

Policy Layer：向用户态开放API，以实现替换、预取等内存管理策略

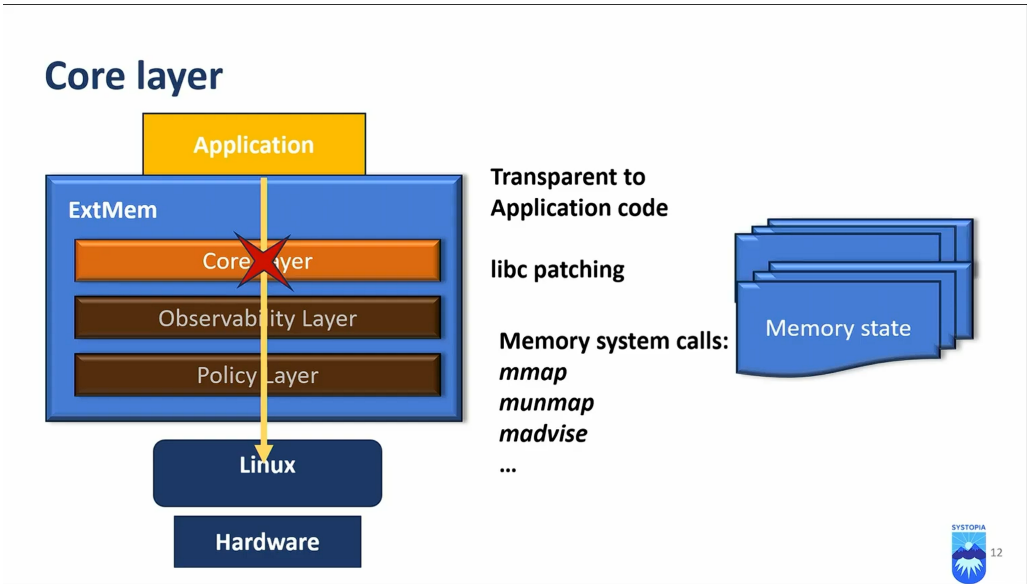

core layer：

Extmem为了让用户能在用户态实现自定义策略，必须将page fault事件从内核态传递到用户态

这一过程需要使用userfaultfd机制：

当应用程序进行内存系统调用时（比如mmap、munmap、madvise），core layer拦截这些调用，将内存区域注册到userfaultfd

当应用程序发生page fault时，若uffd检测出错误来自之前在mmap时，core layer注册到uffd的内存区域，则将错误转发给EXTMEM处理，再把内存管理决策权交给用户态

（syscall_interupt、libc patching——LD_PRELOAD）

（mmap——在调用进程的虚拟地址空间中创建一个新的内存映射

munmap——删除指定地址范围内的内存映射

madvise——向内核提供关于一块内存区域未来使用模式的建议或提示）

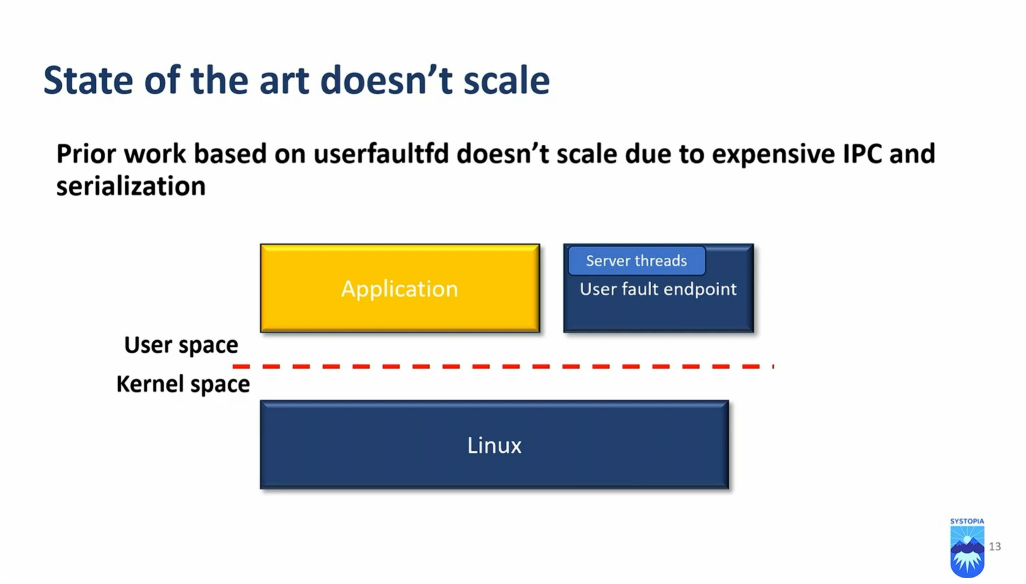

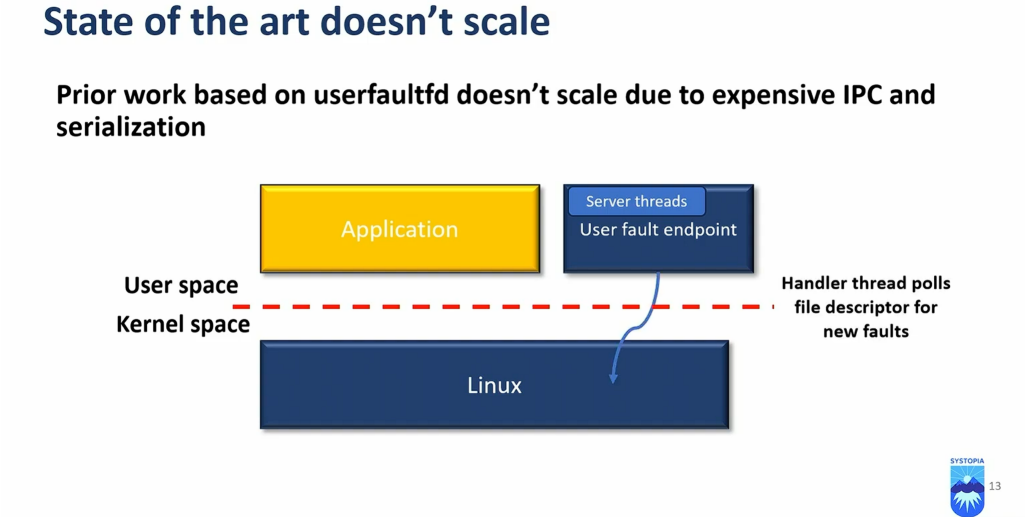

原本的userfaultfd机制是这样的：

首先，在应用程序调用mmap操作的时候，core layer将其拦截下来，将为其分配的内存区域注册到userfaultfd

（Core Layer 调用 `userfaultfd()`，从内核获取一个代表 `userfaultfd` 服务本身的文件描述符（`uffd`），Core Layer 接着使用这个 `uffd`，通过 `ioctl` 命令，将刚刚 `mmap` 的那块内存区域**注册**到这个服务中去）

此时，user fault endpoint——也就是处理page fault的线程，（通过 `poll` 系统调用）监听userfaultfd的消息队列，等待新的page fault发生

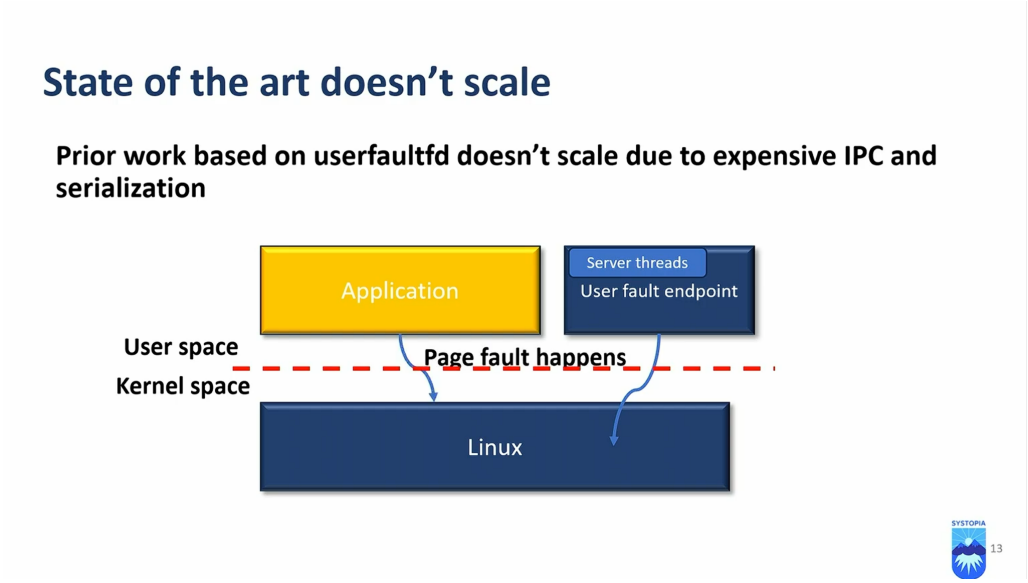

而应用程序之前的mmap操作，只是在进程的**虚拟地址空间**中预留了一段连续的地址范围，**但没有为它分配任何实际的物理内存**

当应用程序对这块mmap分配的虚拟地址空间进行读写操作时，由于没有映射到物理地址空间，会发生page fault，应用程序由用户态转入内核态

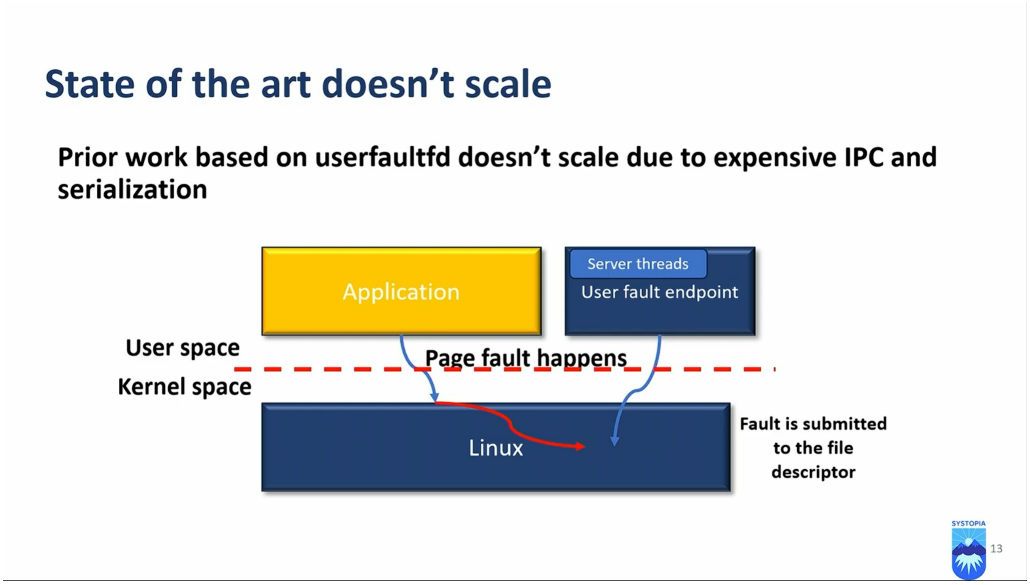

内核将这次缺页的关键信息，如**故障地址**、是**读缺页还是写缺页**打包成一个msg，送入userfaultfd的消息队列中

然后阻塞应用程序进程

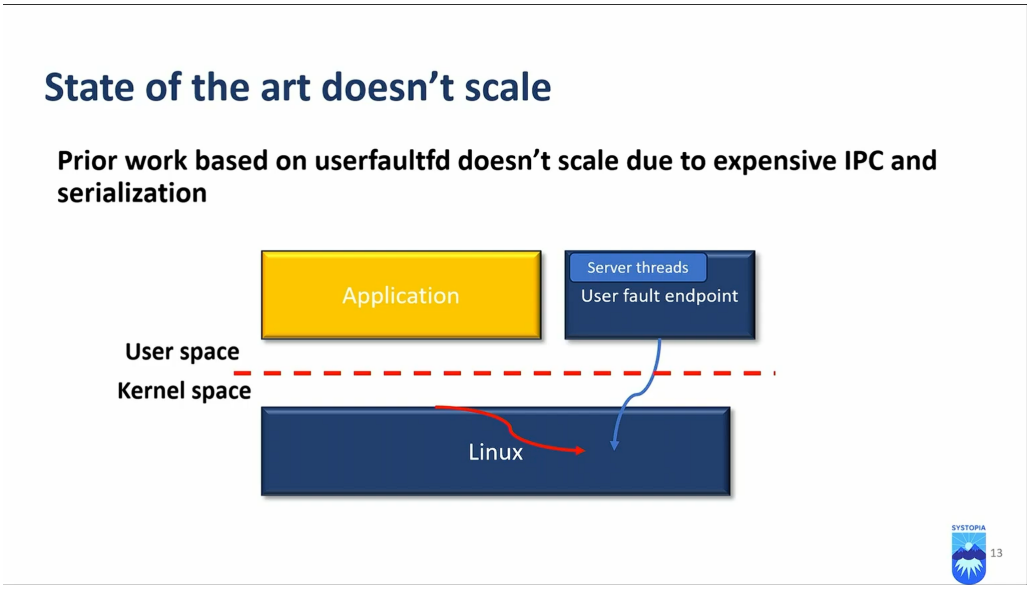

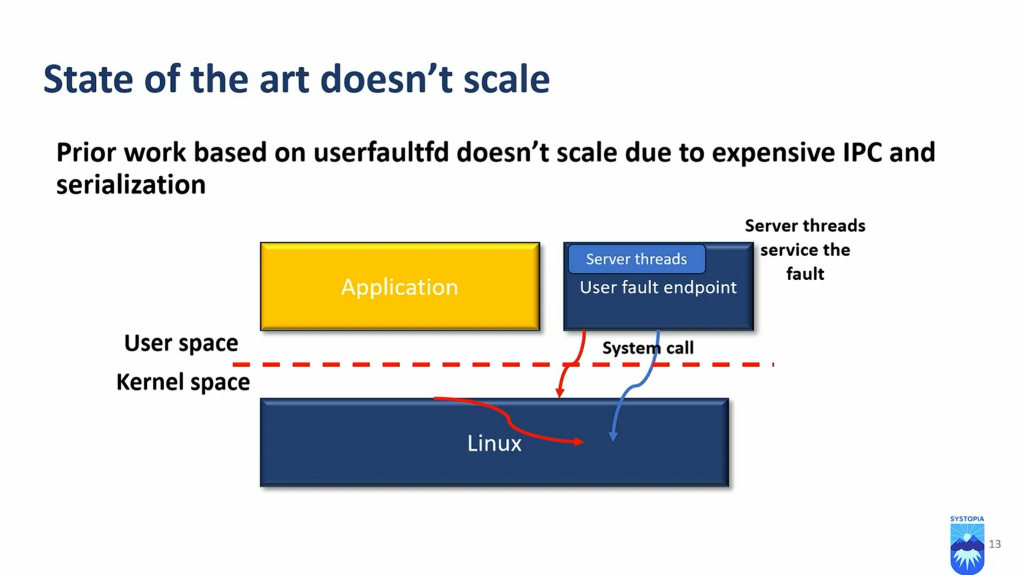

user fault endpoint(Handler thread)从消息队列中取出msg，对其进行处理

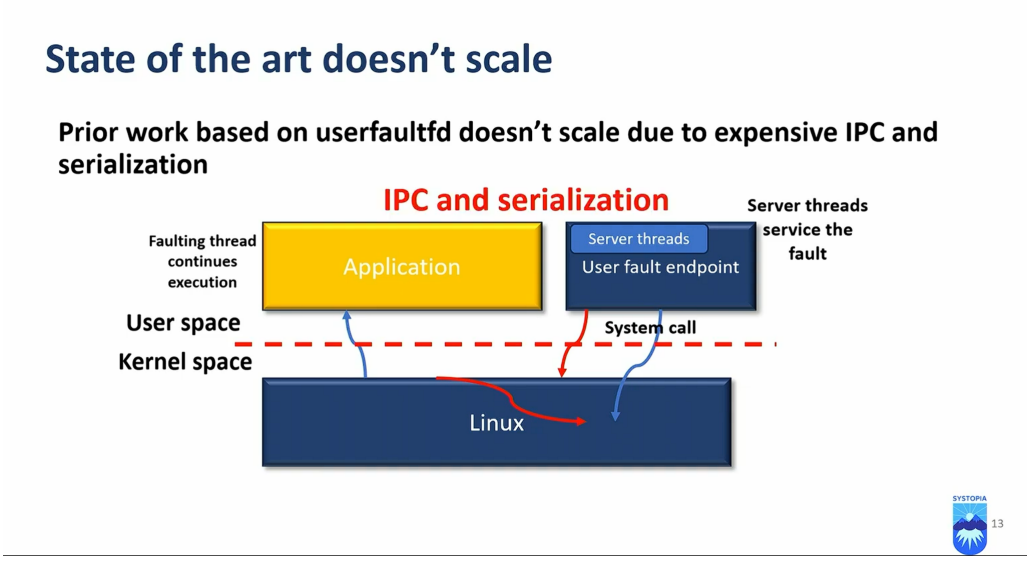

待其处理完毕，唤醒应用程序进程继续运行

faulting thread和handler thread构成IPC机制

一个 handler 线程处理所有缺页，在高并发下会成为瓶颈；若采用多个handler，userfaultfd只有一个消息队列，所有handler对其加锁读，无法发挥handler并发优势

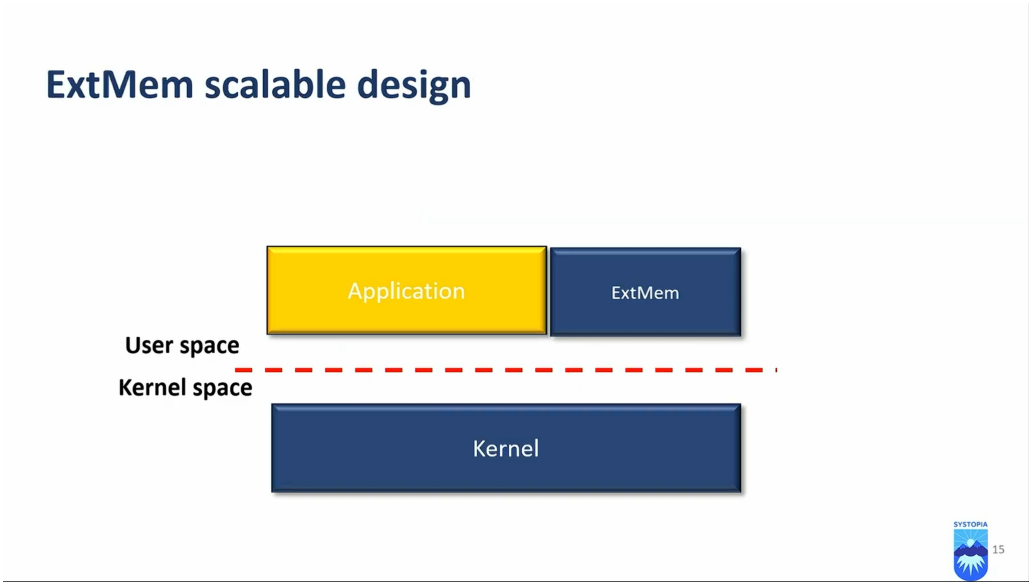

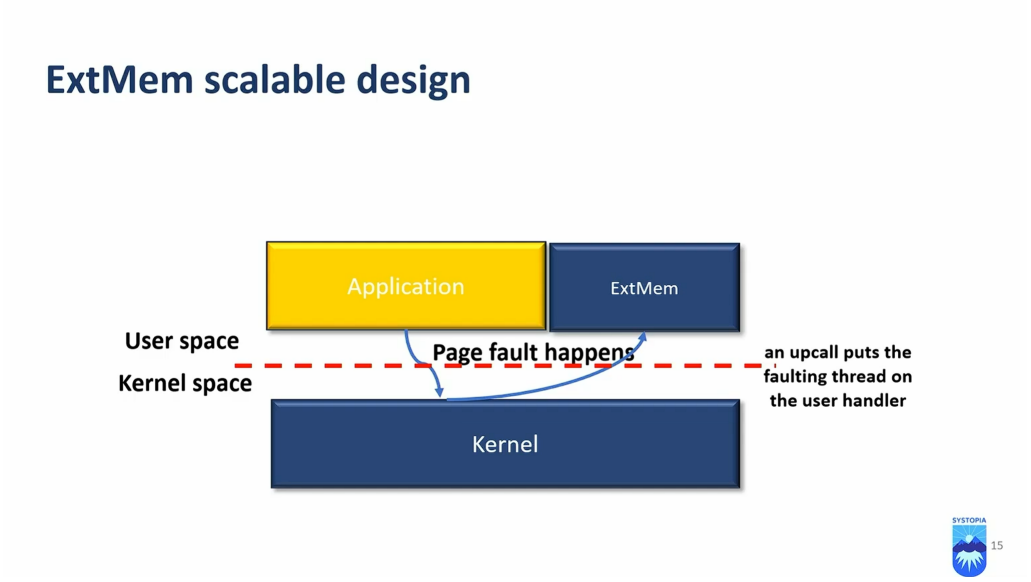

首先，在应用程序调用mmap操作的时候，core layer将其拦截下来，将为其分配的内存区域注册到userfaultfd，同时，为该进程注册一个upcall handler

每当应用程序触发page fault，该fault都会转发到同一进程的用户态

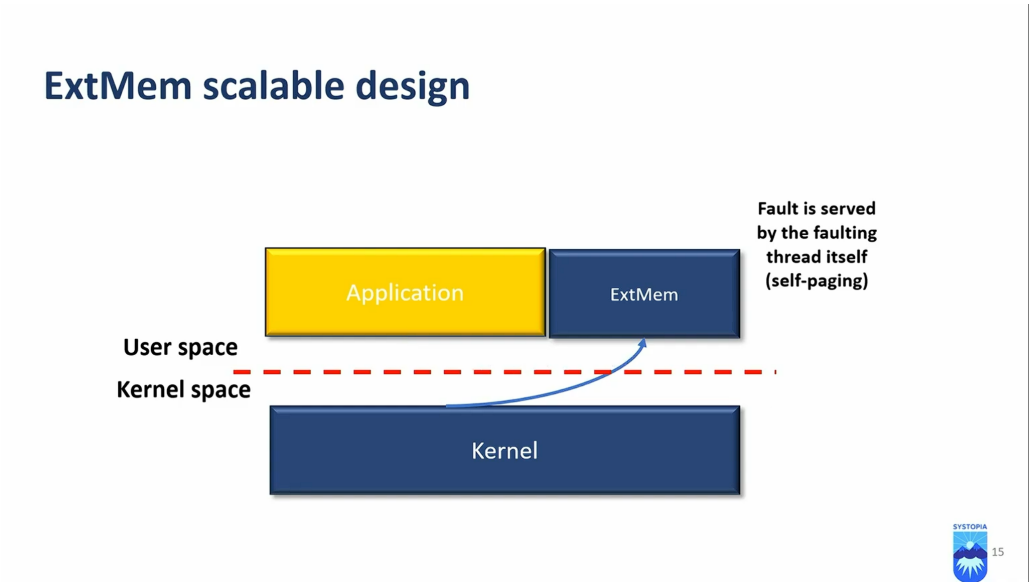

由upcall handler进行处理

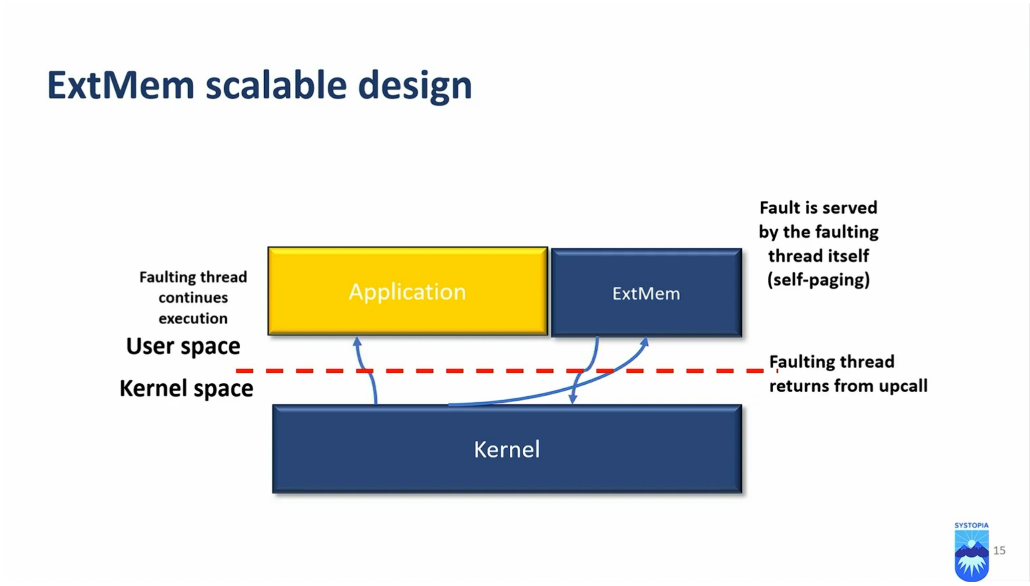

处理完返回应用程序继续执行

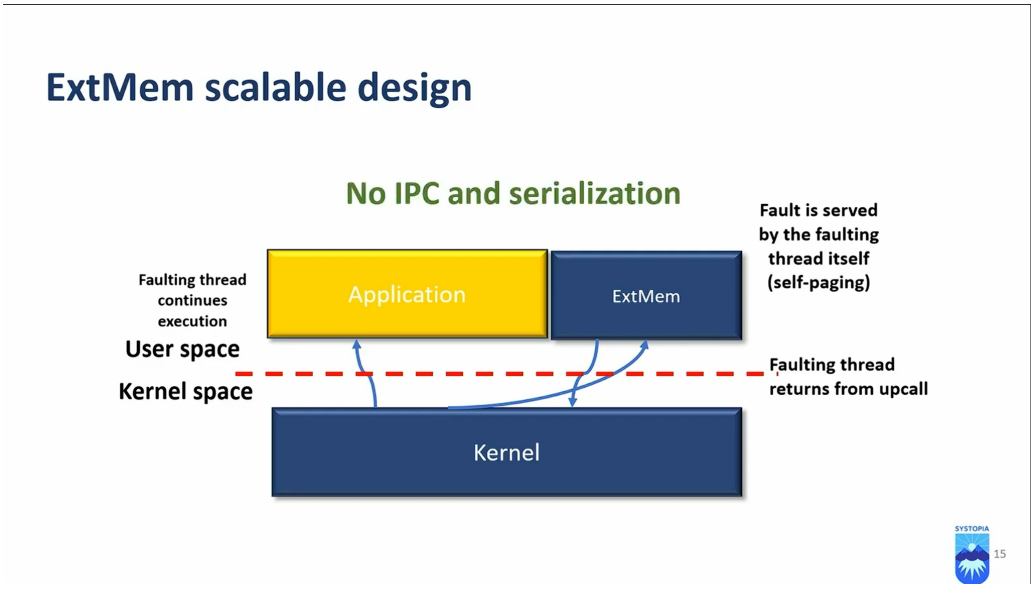

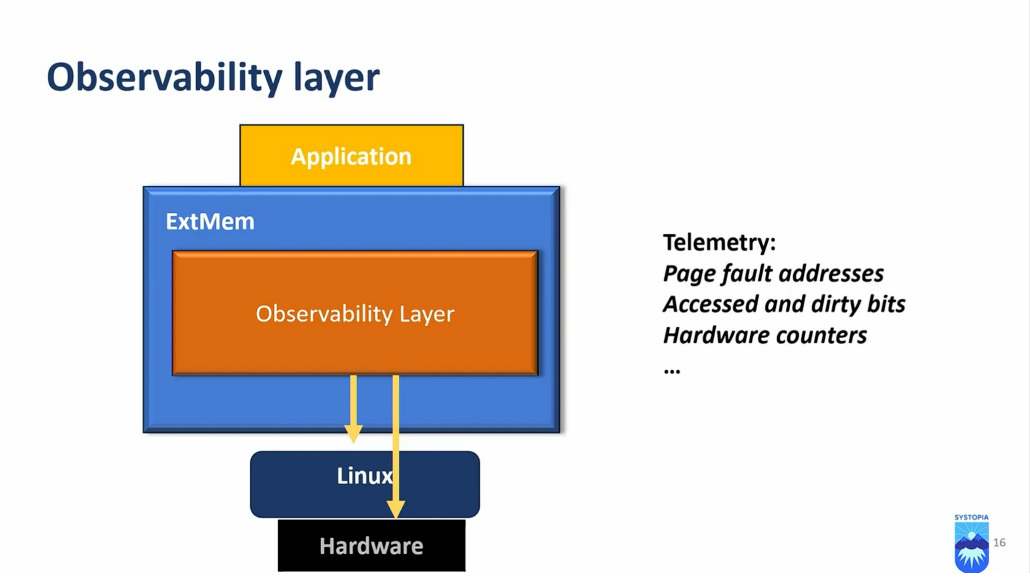

- page fault的故障地址
- MMU访问位和脏位
- Hardware Counter (硬件计数器)

- 位于 CPU 核心中的一组特殊寄存器。它们由一个称为 **PMU (Performance Monitoring Unit, 性能监控单元)** 的硬件子系统管理
- Observability Layer 会**定期地**读取 PMU 中这些计数器的值（执行了多少条指令、发生了多少次缓存未命中 (Cache Misses)、内存带宽的使用情况等）

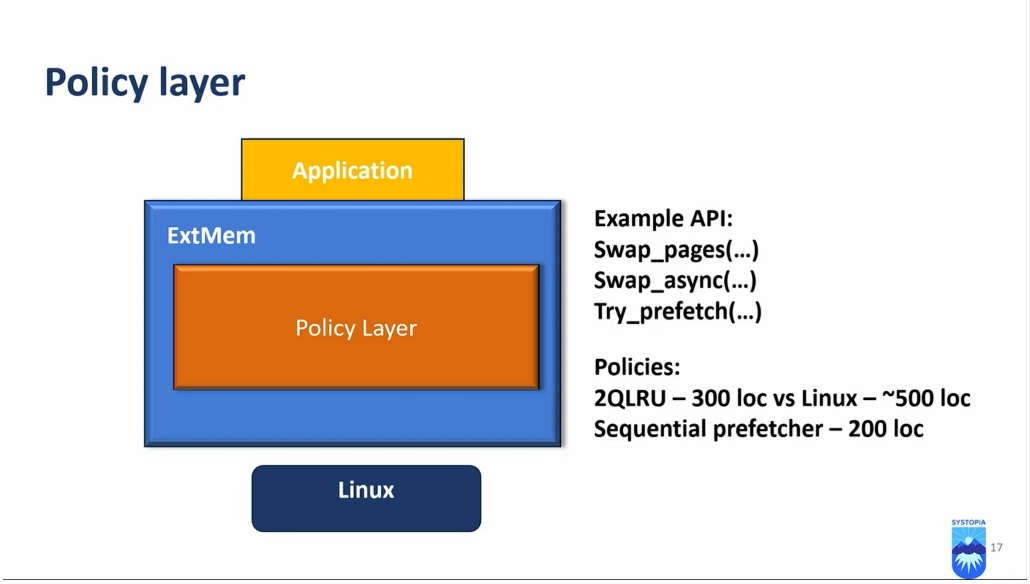

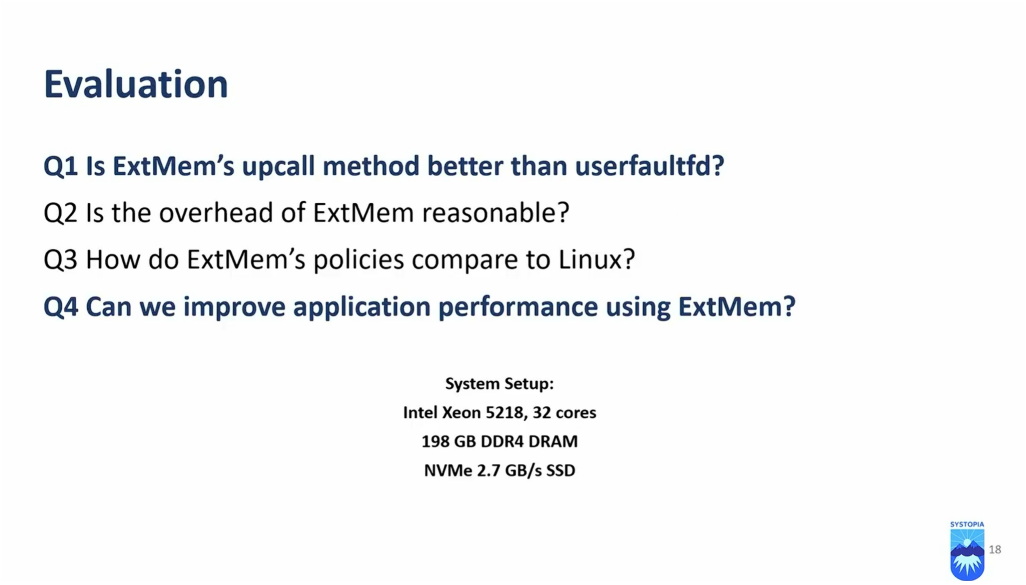

关于ExtMem的性能评估，列出了四个问题（这里主要说明第一个和第四个）

首先，是否ExtMem实现的upcall机制比userfaultfd要好?

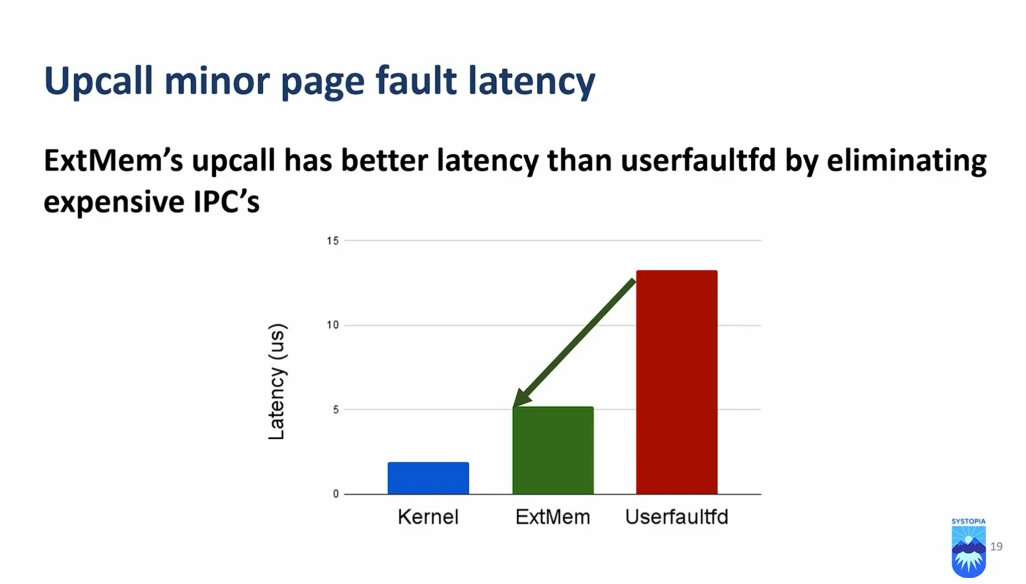

使用单个线程持续访问新分配的内存区域中的页面，记录解决单个page fault的平均延迟（当页面在内存中但未映射到进程页表中时，会出现minor page fault，衡量缺页处理机制本身的路径长短和开销）

由于usefaultfd故障处理路径中的往返IPC，ExtMem的延迟明显比userfaultfd的延迟低

Scalability with concurrent faulting threads

ExtMem's upcall has better scalability than userfaultfd by eliminating serialization

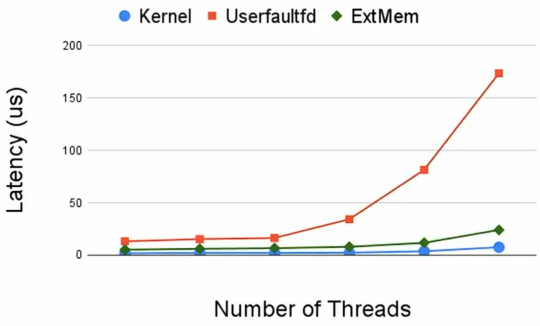

SYSTOPIA 20

接着，使用不同数量的线程持续访问新分配的内存区域中的页面，记录在多线程并发环境下解决单个page fault的平均延迟

由于userfaultfd的待处理队列的读取需要上锁，不能进行并发的读取，发现随着线程数量的增多，ExtMem的延迟明显低于userfaultfd，且差距越来越大

Improving Page rank performance

- A large scale graph processing: PageRank
- Intution: Vertex array stays hot and edge array is cold after being used once.
- Custom Policies:
  - Pin vertex array
  - Discard + prefetch window on edge array

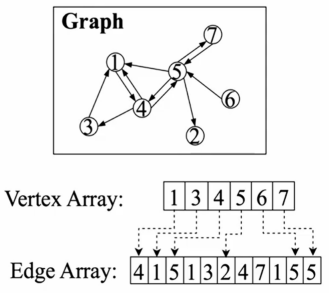

SYSTOPIA 21

第二个要说明的问题是，ExtMem是否能改善应用程序的性能?

论文运行了一个大规模的图处理程序PageRank

- 计算图中每个顶点重要性——反复迭代，根据邻居节点的值来更新每个节点自身的Rank值，直到所有节点的Rank值收敛稳定
- 当一个顶点被访问时，其相邻顶点档大概率被访问

它由顶点数组和边数组两个数组组成

顶点数组：当前index顶点指向边数组中 该顶点自身的邻居顶点列表 的起始位置

边数组：按index存放每个顶点的邻居顶点列表

Page Rank System setup

- Running GAP benchmark suite
- twitter dataset
- 50% (~7GB) fitting in memory
- 4 threads
- Runtime of 10 iterations measured

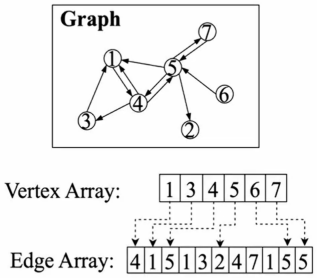

将内存限制在总图大小的50%

Case Study: Page Rank

ExtMem's special policy (ExtMem-PR) has better performance than the Linux default policies

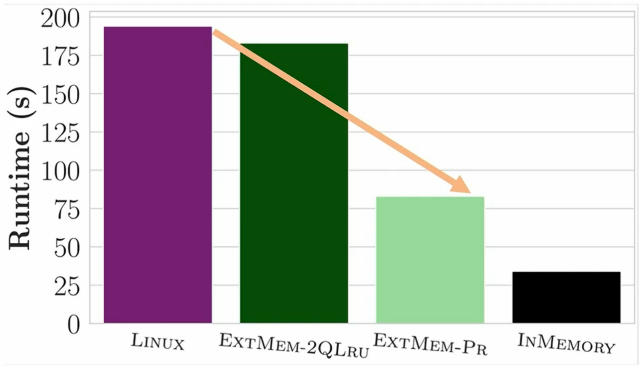

使用与Linux（EXTMEM-2QLRU）几乎相同的算法的EXTMEM会产生适度的改进

- 测试内存压力下的综合性能，除了上述缺页处理机制本身的路径长短和开销，还要考虑页面载入和驱逐问题：当需要的页面不在内存中，必须从磁盘上加载回来，当内存满了，要将页面从内存中驱逐到磁盘空间（handler的部分）
- 而应用程序专属的handler相比于linux为所有应用程序设计的通用handler更快
  - linux handler：不能因为一个程序需要内存，就粗暴地换出另一个重要程序的页面。它必须在所有进程之间做出权衡

    （包含了大量的检查和复杂的逻辑分支：遍历全局的LRU、这个页面属于哪个进程？这个进程是不是已经换出了很多页？——为了公平，不能总从同一个"老实"进程里抢页面）
  - ExtMem：只需要考虑当前这一个应用程序的内存需求，不需要在多个进程间寻求公平

    （从自己的LRU 链表的末尾取出一个页面）

但当我们部署自定义算法（EXTMEM-PR）时，我们获得了超过2倍的加速

EXTMEM-PR

2Q-LRU

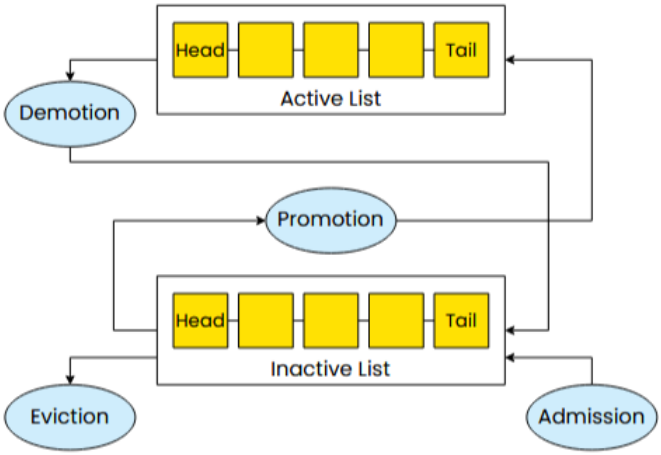
Head
Tail
Active List
Demotion
Promotion
Head
Tail
Inactive List
Eviction
Admission